浙江大学 计算机科学与技术学院
COLLEGE OF COMPUTER SCIENCE AND TECHNOLOGY
ZHEJIANG UNIVERSITY

软件需求工程

Software Requirements Engineering

智能体动态记忆管理系统

Dynamic Memory Management System for Long-term Conversations

Mid-term Presentation 团队：喵喵喵喵喵

小组成员：胡海洋 石子吟 廖若言 路巨聪 叶首状

长对话中的信息会随时间变化

浙江大学 计算机科学与技术学院
COLLEGE OF COMPUTER SCIENCE AND TECHNOLOGY
ZHEJIANG UNIVERSITY

核心背景

- 人物的计划、偏好和状态会在不同 Session 中**持续变化**。
- **普通检索**可能同时召回旧状态、新状态和无关信息。
- 系统需要在回答前判断**哪些记忆仍然有效**。

项目目标

基于 LoCoMo 长对话构建可检索、可追溯的 Memory，识别跨 Session 的状态变化，并依据当前有效记忆生成带证据的答案。

系统范围与使用场景

浙江大学 计算机科学与技术学院
COLLEGE OF COMPUTER SCIENCE AND TECHNOLOGY
ZHEJIANG UNIVERSITY

系统边界

输入：课程选定的 LoCoMo 长对话、用户问题和检索配置。

处理：Memory 构建、相关记忆检索、动态状态解析和依据回答。

输出：结构化 Memory、状态关系、Effective Memory、答案和原始证据。

主要使用者与场景

评测人员提出问题，检查答案、状态关系和证据。

开发人员检查 Memory、检索过程和评测结果。

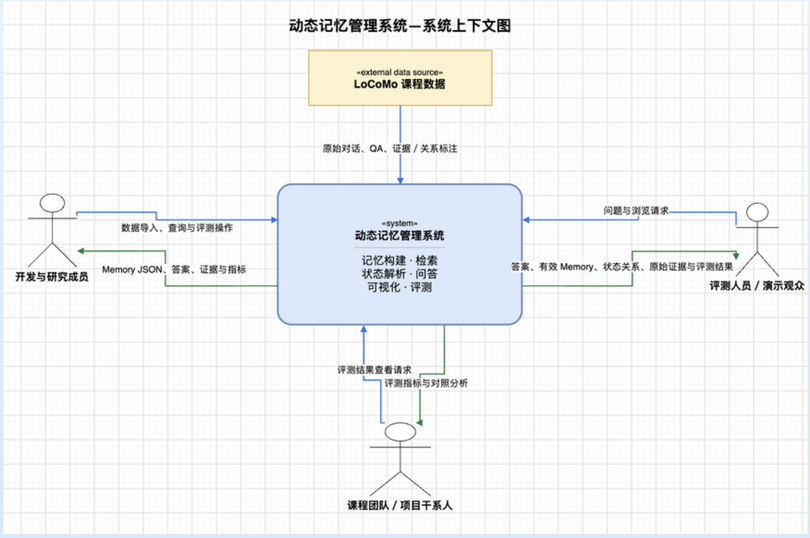
系统面向课程数据的单用户 Web 原型，不处理账号、多人协作和生产部署。

1.3. 系统范围

系统覆盖“对话导入 → Memory 构建 → 初始检索 → 局部状态历史扩展 → 状态解析 → 作答 → 评测”闭环。输入为 LoCoMo 对话、问题及标注；输出为 Memory JSON、候选与有效 Memory、状态关系、带证据的答案及指标，均可回溯到会话与轮次。本期交付单用户 Web 原型：后端提供检索与全链路查询 API，前端展示数据设置、提问、候选记忆、动态状态、答案与证据。其中初始检索和状态解析为当前基线，局部状态历史扩展为 S 级演进需求。系统不面向任意数据集或实时聊天平台，不提供生产部署、账号权限、多人协同与移动端适配，也不自动裁决冲突；完整 Cue－Tag－Content Graph、开放式多跳智能体、Memory 合并压缩与复杂时间推理仅作 Bonus。

系统范围

图



系统上下文

核心需求与验收方式

浙江大学 计算机科学与技术学院
COLLEGE OF COMPUTER SCIENCE AND TECHNOLOGY
ZHEJIANG UNIVERSITY

ID	核心需求	验收方式
FR-MEM	从 LoCoMo 对话构建统一格式的 Memory	Schema 校验通过，证据可回链至 Session 和 Turn
FR-RET	检索Memory与同状态槽位的历史扩展	返回 Top-K 与完整 Memory；专项用例验证遗漏历史能否被补充
FR-STS	判断状态关系并选择 Effective Memory	输出四类关系及理由；冲突或证据不足时返回空答案
FR-API/UI	提供统一接口并展示完整处理链路	前后端契约一致；页面展示候选、关系、答案和证据
FR-EVL	评测检索、状态判断和最终答案	报告 Recall@K、MRR、关系准确率及后续对照实验

关键质量要求

- **可追溯性**：答案能够定位到原始 Session 和 Turn。
- **一致性**：前后端遵守同一组 JSON Schema 和 API 契约。
- **可复现性**：保存数据版本、模型配置和评测结果。



模块	需求编号	核心行为	验收重点／状态
Memory 构建	FR-MEM-01 – 05	解析 session／turn，按 Schema 抽取；合并同事实证据但保留 A→B→A 状态变化；ID 唯一可复现，并有离线基线。	Schema 100% 通过；QA evidence 覆盖率 ＞ 90%；证据可回链。
初始检索	FR-RET-01 – 06	按样本返回 Top-K；支持 BM25／Embedding／Hybrid；分数归一、结果稳定；依赖异常时退回 BM25；完整 Memory 与时间不被修改。	排序、`strategy`、`matched_by` 可检查；无命中或回退标记 `degraded`。
历史扩展	FR-RET-07、FR-STS-09	以初始候选为种子补充同主体、属性的历史，再重建局部状态链；仍缺锚点或冲突未解时停止。	专项用例中召回被 Top-K 遗漏的关键历史；S，未实现。
状态与答案	FR-STS-01 – 08	按同槽位与时间判定 RETAIN／UPDATE／SUPERSEDE／CONFLICT，选择有效记忆；语义模糊时调用模型，失败回退规则。	关系含理由；持续时间具备双锚点；冲突或证据不足时 `answer=null`；答案只引用有效记忆。
服务接口	FR-API-01 – 05	提供健康、样本、记忆、检索、查询端点；Schema 为唯一契约；统一错误结构并限制 `top_k`；提供接口文档。	契约测试通过；404／422 可复现；原始 turn 端点 S，未实现。
Web 展示	FR-UI-01 – 07	展示数据设置、提问、候选、状态、答案与证据；支持模式切换、候选展开、关系高亮和退化提示。	主链路可操作；模拟结果明确标注；证据回跳部分实现，评测页面未实现。
评测	FR-EVL-01 – 06	由 QA evidence 生成检索用例，报告 Recall@K、MRR 与关系指标；运行端到端异常测试，并规划答案及历史扩展对照。	基线评测可复现；答案 F1、Vector RAG 与扩展方案对照未实现。

端到端系统架构

数据处理链路

LoCoMo 对话——>Memory 抽取——>Memory Stor e——>相关记忆检索、动态状态解析——>答案与证据——>W eb 展示

实现边界

- **前端**：React、TypeScript、Vite
- **后端**：FastAPI、Pydantic
- **检索**：BM25、Embedding、Hybrid
- **状态解析**：确定性规则与 DeepSeek Hybrid

从原始对话到可追溯 Memory

浙江大学 计算机科学与技术学院
COLLEGE OF COMPUTER SCIENCE AND TECHNOLOGY
ZHEJIANG UNIVERSITY


```
"memories": [
  {
    "memory_id": "mem-conv30-001",
    "subject": "Jon",
    "type": "state",
    "attribute": "employment_status",
    "value": "unemployed",
    "content": "Jon lost his job as a banker the day before the conversation.",
    "time": {
      "session_id": "session_1",
      "date_time": "4:04 pm on 20 January, 2023",
      "effective_at": "2023-01-19"
    },
    "evidence": [
      {
        "session_id": "session_1",
        "dia_id": "D1:2",
        "quote": "Lost my job as a banker yesterday, so I'm gonna take a shot at starting my own business."
      }
    ],
    "confidence": 0.95
  },
```


Memory 主要字段

- memory_id：唯一标识
- subject / attribute / value：用于状态比较
- content：归一化事实描述
- time.effective_at：事实生效时间
- evidence：来源 Session、Turn 和原文

当前产出

- 已完成 10 个 LoCoMo 对话样本的结构化抽取。
- 已生成约 4,340 条 Memory。
- Memory 可以回链到原始对话证据。

Memory 排序筛选

浙江大学 计算机科学与技术学院
COLLEGE OF COMPUTER SCIENCE AND TECHNOLOGY
ZHEJIANG UNIVERSITY

测试对象

输入同一个问题，在同一个 Memory Store 中对所有 Memory 排序，比较答案所需 Memory 是否进入 Top-K。

具体方法

方法	核心需求	主要特点
BM25	比较问题和 Memory 的关键词及词频	精确词、名称和日期匹配较强；不擅长同义改写
Embedding	将问题和 Memory 转换为向量，比较语义相似度	能识别近义表达；精确词匹配可能不稳定
Hybrid	融合 BM25 分数和 Embedding 分数	同时利用词法和语义信息

我们完成的工作

- 实现三种可切换 Retriever 和统一接口。
- 使用 all-MiniLM-L6-v2 生成语义向量。
- 实现缓存、退化处理和自动评测管道。

初步结果，1,515 个问题

方法	R@1	R@5	R@10	MRR
BM25	29.30%	52.00%	58.70%	0.52
Embedding	30.00%	54.00%	62.50%	0.551
Hybrid	**33.40%**	**57.80%**	**66.60%**	**0.588**

状态关系判断

关系	含义	示例
RETAIN	后续信息确认原事实仍成立	仍然保持健康饮食
UPDATE	后续信息补充兼容的新内容	写书过程中收到反馈
SUPERSEDE	新状态使旧状态成为历史	计划开业变为正式开业
CONFLICT	信息互不相容且无法判断先后	无时间信息的 open 与 closed

判断流程：

1. 使用 **subject + attribute** 找到可比较的 **Memory**。
2. 优先比较 **effective_at** 和明确时间表达。
3. 明确关系由规则直接判断。
4. 语义模糊关系交给 **DeepSeek**，调用失败时回退到保守规则。

动态状态解析实验

每个测试用例包含两条 Memory、问题和人工设定的正确关系标签。系统输出预测标签，再与正确标签比较。

方案	判断方式	实验作用
规则基线	只使用属性、值和时间规则	作为不调用 LLM 的对照方法
混合状态解析	明确关系走规则，语义模糊关系调用 DeepSeek	项目的正式实现方案

当前 16 组关系用例包含 **7 组基础关系**和 **9 组语义挑战**。规则基线为 9/16，其中基础关系 7/7，语义挑战 2/9；规则与 DeepSeek 结合的混合方案在同一批用例上达到 **16/16**。

状态解析只能判断已经进入候选集的 Memory，无法恢复检索阶段遗漏的历史状态。

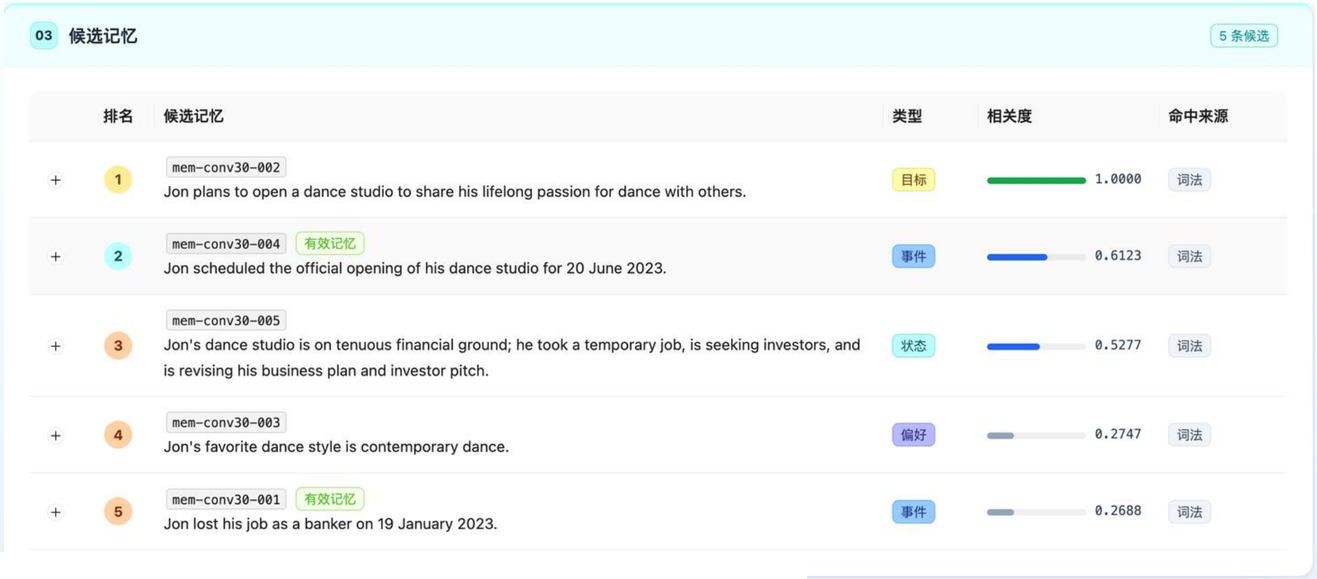
前端展示完整处理链路

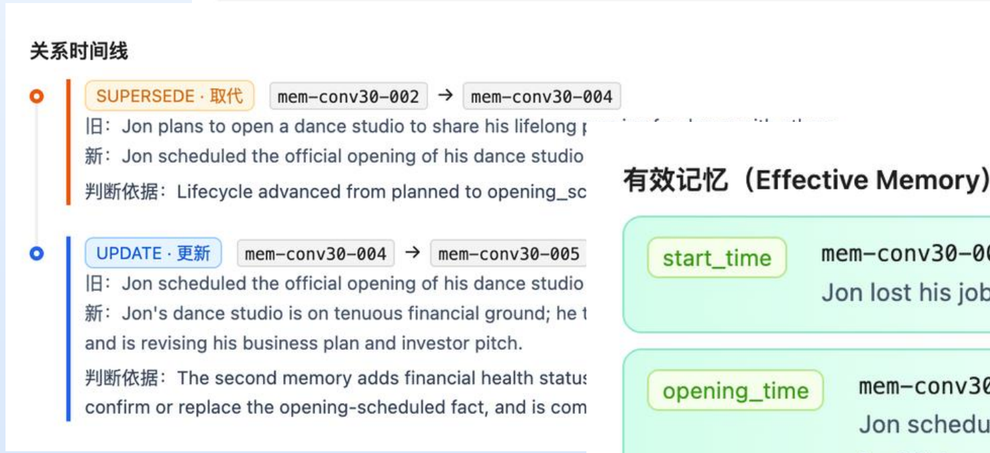
浙江大学 计算机科学与技术学院
COLLEGE OF COMPUTER SCIENCE AND TECHNOLOGY
ZHEJIANG UNIVERSITY

页面组成

- 数据与检索设置：选择样本、Top-K 。
- 提问区域：输入问题或选择演示案例。
- 候选记忆：展示排名、分数和 Memory 内容。
- 动态状态：展示状态关系和判断理由。
- 答案与证据：展示 有效记忆、答案和证据。









中期成果与后续计划

浙江大学 计算机科学与技术学院
COLLEGE OF COMPUTER SCIENCE AND TECHNOLOGY
ZHEJIANG UNIVERSITY

已完成

- 4,340 条可追溯 Memory
- 三种检索策略与统一接口
- 规则和 DeepSeek 结合的状态解析
- SRS、前后端链路与可运行 Demo

当前发现的问题

- 固定 Top-K 按相关性截取候选，可能遗漏同一状态槽位的关键历史。状态解析只能处理已经召回的 Memory，因此无法补全缺失的状态链

下一阶段方案

- 查询驱动的局部状态历史重构
- 思路受到 DimMem 的维度化记忆组织和 MRAgent 主动重构机制启发

下一阶段方案：

初始检索 → 识别主体与属性 → 补充同槽位历史 → 重建状态关系 → 依据有效记忆回答

与固定 Top-K 基线比较必需 Memory 召回、有效记忆判断、答案正确率、扩展候选量和 LLM 调用成本。

浙江大学 计算机科学与技术学院
COLLEGE OF COMPUTER SCIENCE AND TECHNOLOGY
ZHEJIANG UNIVERSITY

软件需求工程

Software Requirements Engineering

欢迎老师同学们批评指正！

小组成员：胡海洋 石子吟 廖若言 路巨聪 叶首状