智能体动态记忆管理系统

软件需求规格说明书（SRS）

软件需求工程 | 团队：喵喵喵喵喵 | 版本：v1.4 | 2026-10-20

1. Introduction

1.1. 目的与读者

本文定义智能体动态记忆管理系统的需求基线：问题、业务目标、参与者与用例、功能与数据要求、外部接口、质量属性、约束，以及需求到用例、接口与测试的追溯关系。读者为课程评审、开发测试与演示人员。需求分 UR／FR／CON，优先级 M／S／C 表示必须／应该／可选，编号全文稳定引用，第 9 章给出统一追溯表。

> 阅读约定　M 为验收必备；S 为应完成、允许标注未完成；C 为本期可选。验收均为可观察、可执行的条件。

1.2. 背景与问题

长程多轮对话中，人物的计划、偏好与状态会随时间变化。全文阅读或普通向量检索能找到相关历史内容，却可能同时返回新旧状态，从而依据过时信息作答。本项目的重点不是“检索到相关文本”，而是在当前时间语境下判断哪些记忆仍然有效、答案能否只由这些记忆支撑。系统以 LoCoMo 为输入，构建可追溯 Memory、检索候选、判定关系并生成带证据的答案；旧事实仅作历史证据。

固定 Top-K 检索只能保证候选与问题在检索分数上的相关性，不能保证同一主体、同一属性的完整状态历史都进入候选集；而状态解析只能处理已经进入候选集的 Memory。当关键前序状态、后续更新或时间锚点被 Top-K 截断时，即使解析规则正确，也无法重构完整状态链。因此，系统以现有混合检索作为可复现基线，并将“由初始候选触发、面向同一状态槽位的局部历史扩展”列为后续应该实现和对照评测的能力。

1.3. 系统范围

系统覆盖“对话导入 → Memory 构建 → 初始检索 → 局部状态历史扩展 → 状态解析 → 作答 → 评测”闭环。输入为 LoCoMo 对话、问题及标注；输出为 Memory JSON、候选与有效 Memory、状态关系、带证据的答案及指标，均可回溯到会话与轮次。本期交付单用户 Web 原型：后端提供检索与全链路查询 API，前端展示数据设置、提问、候选记忆、动态状态、答案与证据。其中初始检索和状态解析为当前基线，局部状态历史扩展为 S 级演进需求。系统不面向任意数据集或实时聊天平台，不提供生产部署、账号权限、多人协同与移动端适配，也不自动裁决冲突；完整 Cue – Tag – Content Graph、开放式多跳智能体、Memory 合并压缩与复杂时间推理仅作 Bonus。

1.4. 术语

Memory 是可独立检索的结构化事实单元，含主体、类型、内容、时间与证据；初始候选 是检索器返回的 Top-K；状态槽位 是由主体与可比较属性标识的一组状态 Memory；扩展候选 是以初始候选为种子、从同一状态槽位补充的历史 Memory；有效记忆 是在当前问题语境下仍成立、可用于作答的 Memory。RETAIN／UPDATE／SUPERSEDE／CONFLICT 分别表示确认保留、同主题补充、旧值被取代、先后不可定；Recall@K 是答案所需记忆出现在前 K 条初始候选中的比例；dia_id 是原始对话轮次的稳定标识。

2. Business Requirements

2.1. 业务目标

编号	业务目标	成功标准
BO-01	结构化记忆构建	10 个样本抽成统一 Schema 的 Memory；正式产物 4340 条，QA evidence 覆盖率 96.4%，全部通过校验。
BO-02	动态状态解析	输出四类关系并选出有效记忆；冲突或证据不足时返回空答案，不编造结论。
BO-03	有依据的问答	答案仅引用有效记忆的证据，100% 可回链 session／turn；检索分数不作为真假或新旧依据。
BO-04	可复现评测与展示	一条命令生成三策略 Recall@K、MRR 与关系准确率；Web 完整展示全链路；测试与构建可重复通过。

业务价值是降低“依据过时信息作答”的风险。Proposal 中的答案 F1 与 Full Text／Vector RAG 对照属后续目标；本期以 Recall@K、状态关系准确率和答案可信性为指标，并如实标注未完成项。

2.2. 产品愿景

产品是面向课程评审与研发成员的长对话动态记忆问答 Web 应用：评测人员输入问题即可查看答案、候选、状态关系与原始证据；开发成员可导入对话、检查 Memory、运行评测并分析错误。与全文上下文或纯相似度检索相比，本系统显式记录来源与时间并在作答前解析状态关系，目标不是“召回更多内容”，而是“依据的记忆当前有效且可追溯”；证据不足时返回空答案。

3. User Requirements

3.1. 参与者

参与者	关注点	主要操作
评测人员／演示观众	答案是否正确、依据是否可见	选样本与 Top-K，提问，查看候选、关系、有效记忆、答案与证据。
开发与研究成员	抽取质量、检索与判断是否可复现	构建 Memory，配置检索与解析模式，运行评测与错误分析。
课程团队／项目负责人	是否满足课程要求、结果是否可信	查看 Web 演示、评测指标与追溯材料。

LoCoMo 是数据源而非 Actor；抽取、嵌入与状态解析器均为系统内部实现。

3.2. 用户需求与用例

需求	用例	目标与主要流程	关联功能
UR-01	UC-01	开发成员：解析 session／turn → 逐 session 抽取 → 补抽未引用 turn → 清洗、合并、校验并导出 JSON。	FR-MEM-01 – 05
UR-02	UC-02	评测人员：选样本与 Top-K 后提问；系统检索候选、解析状态、选有效记忆并返回答案与证据。	FR-RET、FR-STS、FR-API
UR-03	UC-03	评测人员：按排名查看内容、类型、相关度与命中来源，展开查看完整 Memory 与证据。	FR-RET、FR-UI-02/03
UR-04	UC-04	评测人员：以时间线查看四类关系、新旧内容与理由，并查看有效记忆及角色。	FR-STS、FR-UI-04
UR-05	UC-05	评测人员：由答案或 Memory 定位 session／turn 与原文；当前展示 dia_id 与 quote，完整回跳待 turns 接口。	FR-UI-06、FR-API-05

需求	用例	目标与主要流程	关联功能
UR-06	UC-06	开发成员：由 qa.evidence 生成用例，比较三策略 Recall@K 与 MRR，统计关系准确率与混淆矩阵。	FR-EVL-01 – 04
UR-07	UC-07	开发／演示：切换记忆目录、检索策略、解析模式与前端数据模式，确认降级提示与模拟标注。	FR-API-02/03、FR-UI-01/02/05
UR-08	UC-08	开发／评测：对当前状态、状态变化与持续时间问题，以初始候选为种子补充同一状态槽位的相关历史，再解析关系；证据仍不足时返回不确定，并与固定 Top-K 基线对照。	FR-RET-07、FR-STS-09、FR-EVL-06

用例关系：UC-02 包含 UC-03、UC-04，UC-05 在追溯证据时扩展 UC-02，UC-01 是 UC-02 与 UC-06 的前置条件；UC-07 为贯穿演示与评测的配置能力；UC-08 在初始检索可能缺失状态链证据时扩展 UC-02。全部用户需求均有对应功能需求与验收路径，详见第 9 章。

4. Functional Requirements

系统以证据链为主线运行：Memory 构建把原始 turn 转为可比较事实；检索生成相关候选但不判断新旧；状态解析依据属性、时间和必要的模型判断选出有效记忆；API 与 Web 展示过程及答案；评测验证召回、关系和答案。各阶段保留 `sample_id`、`memory_id` 与 `dia_id` 的关联；证据不足、冲突未解或依赖失败时保守返回空结果。

下表按模块汇总细分需求。M／S／C 分别表示必须／应该／可选；“未实现”需求属于后续演进，不计入当前基线成果。

模块	需求编号	核心行为	验收重点／状态
Memory 构建	FR-MEM-01 – 05	解析 session／turn，按 Schema 抽取；合并同事实证据但保留 A→B→A 状态变化；ID 唯一可复现，并有离线基线。	Schema 100% 通过；QA evidence 覆盖率 ⩾ 90%；证据可回链。
初始检索	FR-RET-01 – 06	按样本返回 Top-K；支持 BM25／Embedding／Hybrid；分数归一、结果稳定；依赖异常时退回 BM25；完整 Memory 与时间不被修改。	排序、`strategy`、`matched_by` 可检查；无命中或回退标记 `degraded`。
历史扩展	FR-RET-07、FR-STS-09	以初始候选为种子补充同主体、属性的历史，再重建局部状态链；仍缺锚点或冲突未解时停止。	专项用例中召回被 Top-K 遗漏的关键历史；S，未实现。
状态与答案	FR-STS-01 – 08	按同槽位与时间判定 RETAIN／UPDATE／SUPERSEDE／CONFLICT，选择有效记忆；语义模糊时调用模型，失败回退规则。	关系含理由；持续时间具备双锚点；冲突或证据不足时 `answer=null`；答案只引用有效记忆。
服务接口	FR-API-01 – 05	提供健康、样本、记忆、检索、查询端点；Schema 为唯一契约；统一错误结构并限制 `top_k`；提供接口文档。	契约测试通过；404／422 可复现；原始 turn 端点 S，未实现。
Web 展示	FR-UI-01 – 07	展示数据设置、提问、候选、状态、答案与证据；支持模式切换、候选展开、关系高亮和退化提示。	主链路可操作；模拟结果明确标注；证据回跳部分实现，评测页面未实现。
评测	FR-EVL-01 – 06	由 QA evidence 生成检索用例，报告 Recall@K、MRR 与关系指标；运行端到端异常测试，并规划答案及历史扩展对照。	基线评测可复现；答案 F1、Vector RAG 与扩展方案对照未实现。

5. Data Requirements

原始数据为 `data/raw/locomo10.json`：10 个样本、292 个 session、5882 个 turn（1226 条带图片说明），开发集 8 个、测试集 2 个（conv-49、conv-50）。每样本一个记忆 JSON，含 `memory_id`、`subject`、`type`、`content`、`attribute`、`value`、`time`、`evidence`、`confidence` 与 `sample_id`；`attribute`、`value`、`confidence` 可选，其余必填，`evidence` 至少一条。

时间分三层：session_id 为来源会话，date_time 为对话时间（保留原串、可空），effective_at 为事件生效时间（YYYY-MM-DD，不确定必须为空）。追溯要求 dia_id 真实存在、session_id 由 dia_id 反推、quote 为原文连续子串否则置空但保留 dia_id。

数据分三档：outputs/memories/ 为正式产物（4340 条），data/demo_memories/ 为演示集（conv-30 的 15 条，由 5 条主链路记忆加 10 条干扰记忆组成），data/memories/ 为 5 条回归样本；三者由 DMS_MEMORY_DIR 切换。实测被引用 turn 4143 个、QA evidence 覆盖率 96.4%，无重复 ID 与悬空 dia_id；仅处理课程公开数据，密钥只存于环境变量、.env 或 Keychain。

6. External Interface Requirements

数据契约由 APIs/ 三份 JSON Schema 构成，后两份通过 $ref 复用记忆定义；前端仅提交 sample_id、question、top_k，契约耦合集中在类型定义与请求封装。

配置分四组：检索侧 DMS_RETRIEVER、DMS_EMBEDDING_MODEL、DMS_MEMORY_DIR；状态侧 DMS_STATE_RESOLVER、DMS_LLM_PROVIDER、DMS_LLM_MODEL 及密钥（默认 rules 不联网）；前端 DMS_API_TARGET 指定代理目标并使用 /api；命令行提供启动、数据重建、验收及抽取、评测、测试命令。外部模型采用 OpenAI 兼容 REST，要求超时、重试与结构化校验，失败回退规则。

7. Quality Attributes

可追溯性最高：4340 条正式记忆与演示集 15 条均至少一条有效证据，答案证据全部来自有效记忆，可回链率 100%。

检索正确性在 1515 个自动用例上衡量：混合策略 R@1/3/5/10 为 0.334/0.510/0.578/0.666，MRR 0.588；回归下限建议 R@5 ⩾ 0.55、R@10 ⩾ 0.62。状态判断正确性：规则基线 16 组通过 9 组（56.25%，CONFLICT 2/2、UPDATE 3/4、SUPERSEDE 3/7、RETAIN 1/3），仅作回归基线。可信性：检索退化、冲突未消解、缺时间锚点或仅主体命中时均返回空答案，虚构答案为 0 条。可复现性与性能由确定性检索、哈希缓存与脚本用例保证：1515 用例三策略 27 秒、模型加载 5.3 秒；可维护性依靠 Protocol 边界与契约测试，85 项测试 1.1 秒全绿。

8. Constraints

8.1. 数据与范围约束

- CON-01（数据范围） 仅处理 LoCoMo 10 个样本（8 开发、2 测试）；结果不得推广到开放领域或生产环境。
- CON-02（评测隔离） 抽取只读 conversation，不得用 QA 三字段选择 turn 或指导抽取；QA 仅用于事后评测。
- CON-03（证据与时间） 每条 Memory 至少一条真实 dia_id；effective_at 不确定则 null；旧记忆保留。

8.2. 技术与运行约束

- CON-04（技术栈） Python 3.11/FastAPI/Pydantic v2；React 18/TS/Vite；契约 JSON Schema；数据存 JSON。
- CON-05（离线与降级） 无网络或无 Key 可运行：BM25 + rules 离线；语义或 LLM 不可用时回退规则。
- CON-06（单机与单用户） 单机单用户，不要求 GPU；无账号、权限、多租户、并发与高可用；嵌入模型约 90 MB。

8.3. 项目与合规约束

- CON-07（进度与范围） 按 DDL 交付；未实现需求须标注，不得用模拟冒充真实输出，模拟链路须常驻提示。
- CON-08（数据与密钥合规） 只用公开数据；Key 仅存环境变量、.env 或 Keychain，不入仓库、日志或文档，错误不回显。

- CON-09（交付边界） 中期核心为 Web 原型、Memory、测试与评测；轻量的同槽位局部历史扩展属于 S 级演进，完整 Cue – Tag – Content Graph、开放式多跳智能体、生产部署、移动端与自动裁决不验收。

9. Requirements Traceability

需求	验证	状态
UR-01 – 08（UC-01 – 08）	`demo/verify_demo.py` 8 项、Web 验收、`npm run build`；UC-05 仅到 `dia_id`／`quote`；UC-08 通过状态链遗漏专项用例验证	UC-01 – 07 已实现，UC-05 部分；UC-08 未实现
FR-MEM-01 – 05	`test_extract.py`：完整性、schema、补抽不依赖 QA、状态合并与回环	实现
FR-RET-01 – 06、FR-STS-01 – 08	`test_retrieval.py`、`test_embedding.py`、`test_dynamic_state.py`、`test_api.py`、`test_llm_relation.py`：排序、降级、关系、双锚点、不虚构、回退	实现
FR-API-01 – 04、FR-UI-01 – 05、FR-EVL-01 – 04	`test_api.py`、`test_contract.py`、`demo/verify_demo.py` 8 项检查、`test_evaluation.py`、`npm run build`	实现
FR-API-05、FR-UI-06 – 07、FR-EVL-05	无	未实现
FR-RET-07、FR-STS-09、FR-EVL-06	状态链遗漏专项用例；与固定 Top-K 基线比较必需 Memory 召回、有效记忆判断、答案正确率、扩展量与模型调用次数	S，未实现
CON-01 – 09	配置检查、抽取约束测试、密钥扫描与人工复核	执行中