浙江大学 计算机科学与技术学院
COLLEGE OF COMPUTER SCIENCE AND TECHNOLOGY
ZHEJIANG UNIVERSITY

软件需求工程

Software Requirements Engineering

智能体动态记忆管理系统

Dynamic Memory Management System for Long-term Conversations

Final Presentation **团队：喵喵喵喵喵**

小组成员：胡海洋 石子吟 廖若言 路巨聪 叶首状

项目目标与核心需求

浙江大学 计算机科学与技术学院
COLLEGE OF COMPUTER SCIENCE AND TECHNOLOGY
ZHEJIANG UNIVERSITY

核心背景

- 长期对话中，人物的计划、偏好和状态会随时间改变。
- 全文阅读成本高，普通检索又可能同时取回新旧事实。
- 目标：在 LoCoMo 长对话上构建可追溯 Memory，识别状态变化，依据有效证据作答；证据不足时拒绝猜测。

结构化 Memory 与 JSON

2,882 条 Memory · 6 样本

- 记录 memory_id、主体 / 属性 / 值、观测与生效时间
- 来源回链到 session / turn 和原文
- 统一 JSON Schema，校验通过

动态维护与有效记忆

4 类 状态关系，附判断理由

- RETAIN · UPDATE · SUPERSEDE · CONFLICT
- 旧 Memory 不删除，标记为历史
- 集合事实不机械互斥；冲突或缺时间锚点时保守处理

有据回答与 Web 可视化

3 层 候选·规则·引用分开

- 页面展示 Top-K、扩展来源、状态关系、Graph 路径
- 答案附 Memory ID 与原始证据
- 引用 ID 在边界层严格校验

系统总体架构



只有 Memory 抽取与最终作答调用模型；检索、建图、遍历、规则分析和引用校验都在本地完成。

实现边界

- **前端：**React、TypeScript、Vite
- **后端：**FastAPI、Pydantic，前后端共用严格 JSON 契约
- **检索：**Hybrid = BM25 0.4 + all-MiniLM-L6-v2 0.6
- **作答：**deepseek-flash，温度 0，输出 ⩽128 token

设计原则

- **可追溯：**每个答案回链 Memory ID 与原始 session / turn
- **按需扩展：**Graph 只在证据不足时触发，不对每题注入
- **保守失败：**证据不足或冲突无法消解时返回 null，不用模板兜底

Memory 与动态关系

浙江大学 计算机科学与技术学院
COLLEGE OF COMPUTER SCIENCE AND TECHNOLOGY
ZHEJIANG UNIVERSITY

Memory 主要字段

- **memory_id**：唯一标识
- **subject / attribute / value**：主体与状态槽位，用于比较
- **content**：可独立检索的事实描述
- **观测时间 vs 生效时间**：对话发生时间不自动等于事件时间
- **evidence**：来源 session、turn 和原文
- **historical / conflicting**：旧 Memory 不删除，只标记状态

关系	含义	处理
RETAIN	后续信息确认原事实仍成立	保留为有效
UPDATE	补充兼容的新内容	合并为当前状态
SUPERSEDE	新状态使旧状态成为历史	旧条目标记历史
CONFLICT	互不相容且无法判断先后	标记冲突，保守作答

三层信息分开展示，不混为一谈

候选 Memory
检索 Top-K 与扩展

≠

规则建议
Effective Memory，可审计提示

≠

LLM 实际引用
经 ID 校验

明确时间优先比较；规则只给提示，最终答案必须由模型引用当前候选中的 Memory。

Graph Memory 与自适应检索

浙江大学 计算机科学与技术学院
COLLEGE OF COMPUTER SCIENCE AND TECHNOLOGY
ZHEJIANG UNIVERSITY

图模型：只用结构化 Memory 建图

memory	subject	slot
value	session	turn

边： ABOUT · IN_SLOT · HAS_VALUE · OBSERVED_IN · SUPPORTED_BY · NEXT_STATE · NEXT_TURN
不读取 QA 标准答案或评测标签。

有界多跳遍历

- 从 Hybrid Top-K 种子出发，**最多 4 跳、新增 ≤ 8 条**
- **排序：** 25% 路径先验 + 75% 问题相关性
- **精度防线：** 命名实体范围、集合槽位主题过滤、通用词过滤
- 新增证据标记 **graph_supplemental**，返回路径与分数

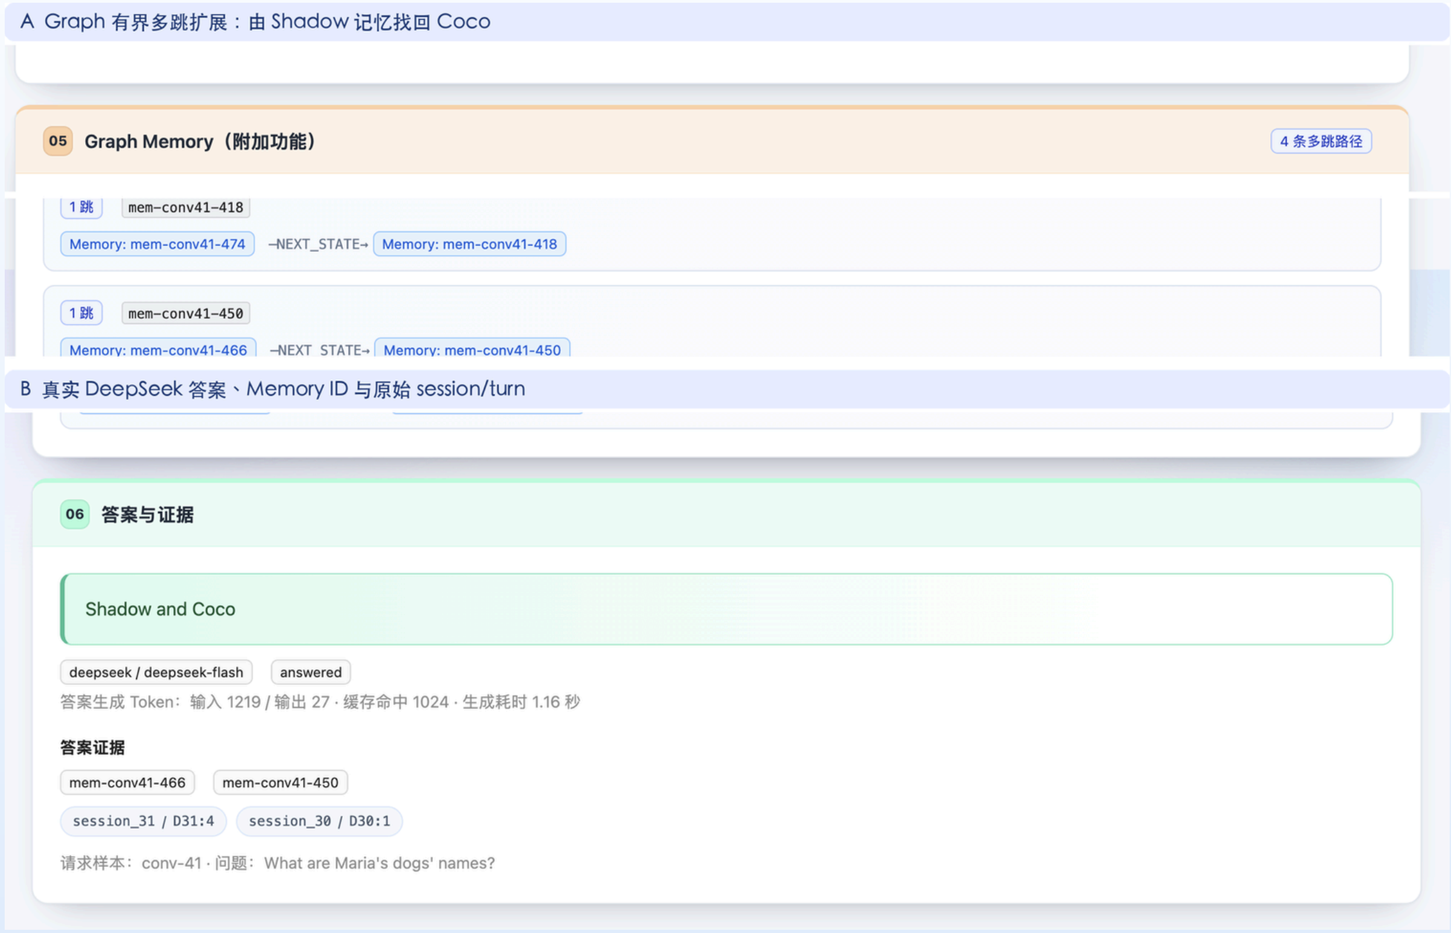
自适应路由

Top-K 先作答
只用初始证据
→ **需要补证据?**
拒答 或 复数姓名题
→ **Graph 扩图重试**
沿路径补回缺失 Memory
→ **引用校验后输出**
答案 + Memory ID

否则直接输出原答案。 复数姓名题的新答案只在“引用更多 Memory 且实际用到 Graph 新证据”时覆盖旧答案。

可运行应用与证据链

浙江大学 计算机科学与技术学院
COLLEGE OF COMPUTER SCIENCE AND TECHNOLOGY
ZHEJIANG UNIVERSITY



当前 Web 真实 DeepSeek 查询：“What are Maria's dogs' names?”(conv-41)

一条完整证据链

1. Top-K 只找到 Shadow（mem-conv41-466）
2. Graph 沿 NEXT_STATE 一跳找回 Coco（mem-conv41-450）
3. DeepSeek 输出 “Shadow and Coco”，F1 = 1.0
4. 回链 session_31 / D31:4 与 session_30 / D30:1

中期 → 最终改进

最短完整答案 · 列表不漏项
字符串 "null" 归一化为拒答
引用 ID 严格校验，无模板兜底

实验设计与验证

项目	配置
数据划分	开发 conv-41/42/43/44（650 题）；测试 conv-47/48（340 题）
两次运行	v1：旧提示词，DeepSeek + GLM v2：最终提示词，DeepSeek
对照方法	Full Text · Embedding K5 · Hybrid K5 · K5+补检 · K10 · Forced / Adaptive Graph
作答	deepseek-flash，温度 0，最大输出 128 token（v2）
统计	逐题配对 bootstrap 5,000 次，给出 95% 置信区间
一致性	两次运行的题单、对话、Memory、检索代码 SHA-256 完全一致

340 + 650

测试集 + 开发集题数

7 × 2

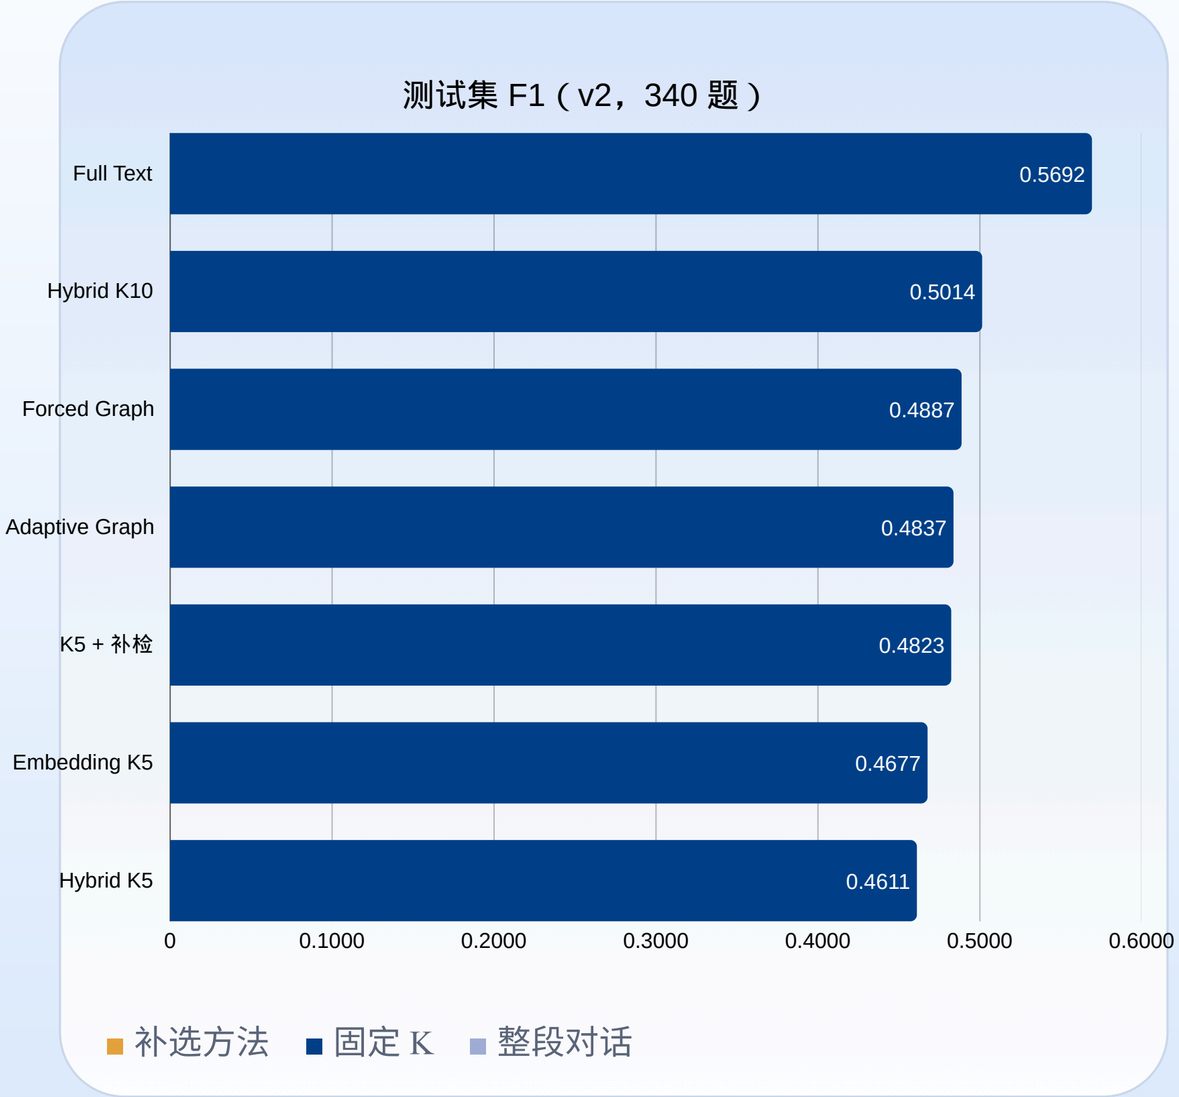
种方法 × 次运行，接口错误 0

198 passed

Python 全量测试；前端构建通过

主结果：补选稳定有效

浙江大学 计算机科学与技术学院
COLLEGE OF COMPUTER SCIENCE AND TECHNOLOGY
ZHEJIANG UNIVERSITY



方法	EM	召回	候选	输入 Token
Full Text	0.3500	—	—	20,139
Hybrid K10	0.2941	67.45%	9.99	1,238
Forced Graph	0.2971	66.55%	9.75	1,263
Adaptive Graph	**0.2912**	**63.89%**	**6.36**	**949**
K5 + 补检	0.3000	64.97%	6.81	985
Embedding K5	0.2794	59.20%	5.00	795
Hybrid K5	0.2735	59.92%	5.00	825

+2.6 pp

Adaptive vs K5，测试集 14 升 / 0 降

+1.5 pp

开发集 650 题复核，19 升 / 0 降

精度与上下文成本的折中

补选 vs K5

同版本内稳定有效

- 补检 **+2.1**，Forced **+3.1**，Adaptive **+2.6** pp
- **95% CI 均不含 0**
- 开发集同样成立

Adaptive vs Forced

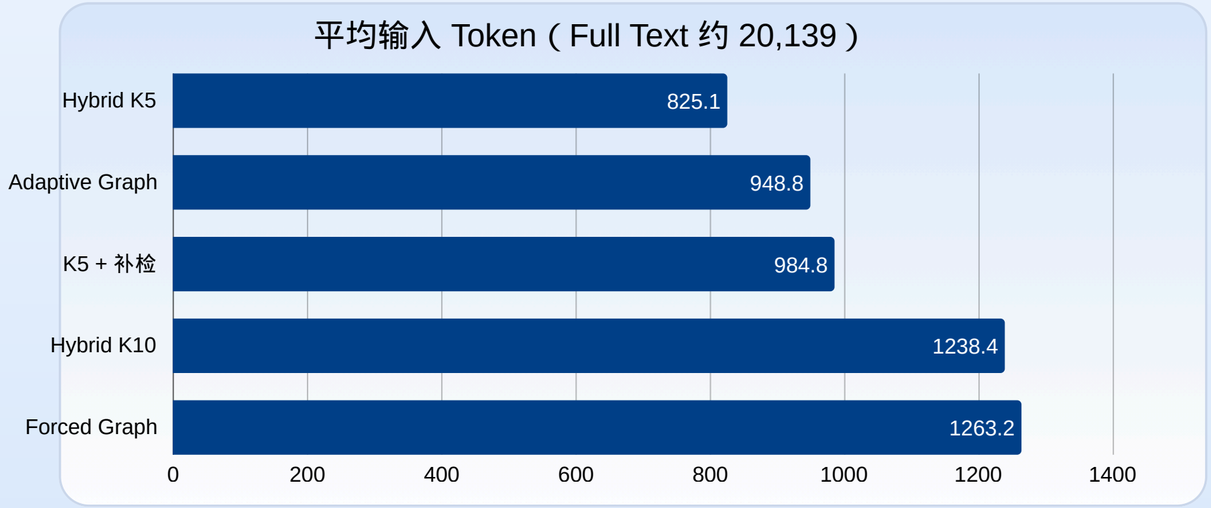
精度相当，更稳更省

- F1 差的 CI 在两个集合都跨 0
- 下降题：**0** vs 测试 10 / 开发 **32**
- 输入 Token **−25%**

补选 vs K10

没有超过 K10

- K10 高 **1.8 pp**（CI 刚好跨 0）
- 但 K10 多用 **30%** 输入
- 补选拿回 K5→K10 **一半以上**收益



提示词版本效应（v1 → v2，同题配对）

所有方法 F1 提升 **6–8 pp**，CI 均不含 0

K5 + 补检：0.4075 → 0.4823

总提升主要来自答案约束，补选在其上再加 2–3 pp

案例、结论与局限

案例

- **正例：**Maria's dogs' names — Top-K 只有 Shadow，Graph 补回 Coco，答案 “Shadow and Coco”，F1 = 1.0
- **测试集 James's dogs：**从拒答变为完整答出三个名字
- **边界：**强制扩图曾把日期答成 “Yesterday”、被无关证据带偏时间

结论

- V1基础系统 F1 0.3976 → 最终 **0.4837**：答案约束 +6–8 pp，补选再 +2–3 pp
- 自适应补选在测试集与开发集都 **0 题下降**
- K10 精度略高、Full Text 最高，但上下文更贵：系统提供精度与成本的可选折中

局限

- 自定 4 开发 / 2 测试划分、单轮问答，不能外推开放域
- 最终运行只用 DeepSeek；GLM 仅有旧版数据
- 缺端到端关系金标；token F1 惩罚近义与日期表达
- Graph 为有界遍历，不是因果推理 Agent

参考：Maharana et al., Evaluating Very Long-Term Conversational Memory of LLM Agents (LoCoMo), ACL 2024；DimMem；MRAgent
结果：docs/results/consolidated-results.md