智能体动态记忆管理系统：最终报告

Agent Dynamic Memory Management System for Long-term Conversations 软件需求工程 · 团队：喵喵喵喵喵 · 成员：胡海洋、石子吟、廖若言、路巨聪、叶首状 · 2026-11-08

1. 项目目标、需求与总体设计

摘要

长期对话中的人物状态、计划和偏好会随时间改变。全文阅读成本高，普通向量检索又可能同时取回新旧事实。本项目面向 LoCoMo 长对话，实现结构化 Memory 构建、Hybrid 检索、动态状态解析、Graph Memory 有界多跳补检、DeepSeek 作答、引用校验与 Web 可视化。系统以可追溯证据为核心，保留历史事实，在证据不足时拒绝猜测。

核心需求与交付

需求	实现与验收
结构化 Memory 与 JSON	记录 `memory_id`、主体/属性/值、时间和来源 session/turn；6 份冻结样本共 2,882 条 Memory，Schema 校验通过。
动态维护与有效记忆	输出 RETAIN、UPDATE、SUPERSEDE、CONFLICT 及理由；集合事实不机械互斥，冲突或缺锚点时保守处理。
有据回答与 Web 可视化	页面展示 Top-K、扩展来源、状态关系、Graph 路径、答案、Memory ID 与原始证据；作答引用仅允许来自当前候选。

总体链路

`LoCoMo` 对话 → `Memory` 抽取/校验 → `Hybrid Top-K` → 可选补检/`Graph` → 关系与时间规则 → 证据包 → `DeepSeek` 最短作答 → 引用校验/`Web`



系统总体架构与数据流

图 1　系统总体架构。 Graph 是按需触发的证据恢复环节，最终答案仍必须通过引用边界校验。

其中 Memory 构建、检索、建图、遍历、规则分析和校验在本地完成；只有结构化 Memory 抽取与最终答案生成需要调用模型。前后端分别使用 FastAPI/Pydantic 与 React/TypeScript/Vite，并共用严格 JSON 契约。

2. 关键实现与中期后改进

2.1 Memory、时间与动态关系

Memory 以可独立检索的事实为粒度，同时保留对话观测时间与事件生效时间。解析器按主体与状态槽位比较 Memory，明确时间优先，旧 Memory 不删除而是标记为历史。规则选中的 Effective Memory 是可审计提示，不与 LLM 最终引用混为一谈。

2.2 两类补检与 Graph Memory（附加功能）

- **查询驱动证据补检**：从 Top-K 种子识别主体/属性，补全同槽位历史；超出预算、无种子或缺少状态锚点时保守停止。
- **Graph Memory**：将 Memory、Subject、Slot、Value、Session 和 Turn 显式建图，使用 NEXT_STATE、IN_SLOT、SUPPORTED_BY、NEXT_TURN 等边执行最多 4 跳、最多 8 条新 Memory 的有界遍历；每条新候选返回路径和分数。
- **精度防线**：命名实体范围、集合槽位主题相关性和通用词过滤阻止跨人物/无关连边；Graph 证据标记为 `graph_supplemental`。

2.3 自适应 Graph 与统一作答

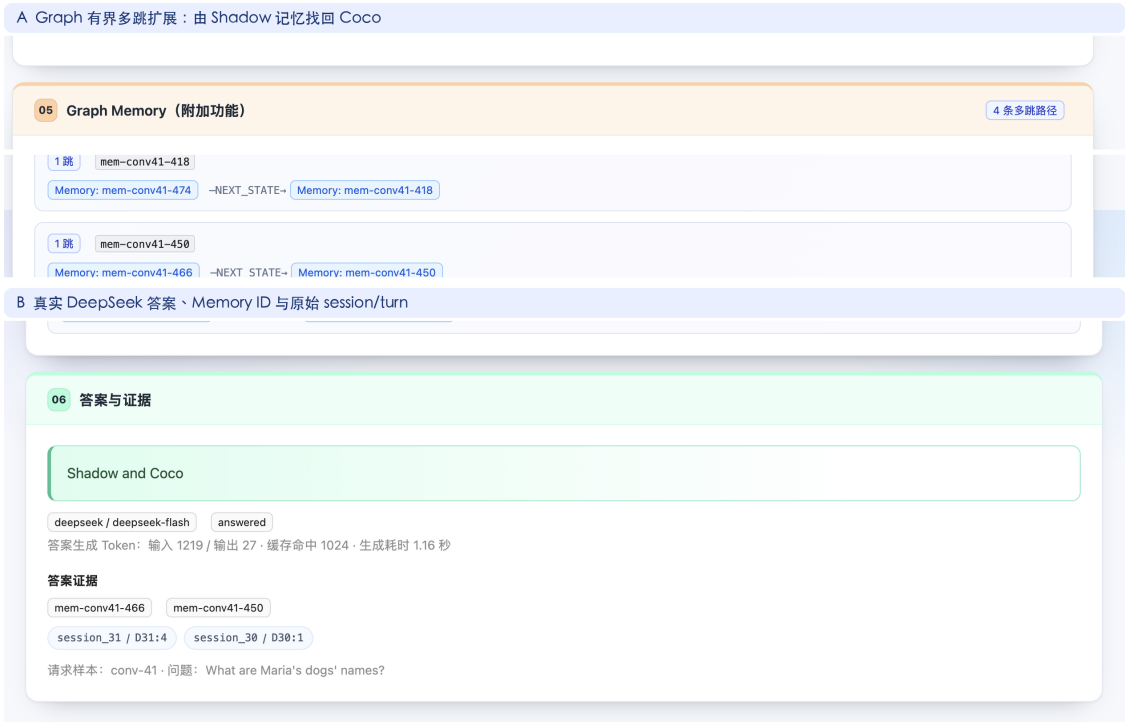
中期后的关键变化是不再对每题强制扩图。系统先用 Top-K 作答；只有模型因证据不足而拒答，或问题明确要求复数姓名补全时，才启动 Graph 重试。复数姓名的新答案只在“引用更多 Memory 且实际使用 Graph 新证据”时覆盖旧答案，否则回退。

回答模型只读有界证据，输出最短但完整的答案片段与 Memory ID；时间、时长、人物类问题保留所问粒度，复数/列表题不得为简短而丢项。无效 ID、空引用或字符串 `"null"` 都在边界层校验或归一化，不使用模板答案兜底。

中期状态	最终改进
固定 Top-K，状态解析无法恢复候选外证据	同槽位补检 + Graph 多跳路径
Graph 一律扩展，简单题受噪声干扰	拒答/明确列表才自适应重试
长句和额外解释拉低 token F1	最短完整答案 + 列表完整性约束
候选、规则建议与答案引用易混淆	三者分层展示，引用 ID 严格校验

3. 功能验证与实验方法

3.1 Web 功能与可追溯性



当前 *Web* 中的自适应 *Graph* 查询、路径与答案证据

图 2　真实 DeepSeek 查询的完整证据链。 初始 Top-K 只找到 Shadow；Graph 沿 `NEXT_STATE` 找回 `mem-conv41-450`（Coco），最终输出 `Shadow and Coco`，并回链 `session_31/D31:4` 与 `session_30/D30:1`。

3.2 数据、方法与指标

项目	冻结配置
数据划分	自定开发集 `conv-41/42/43/44`；测试集 `conv-47/48`；最终 340 道 category 1–4 QA
检索/图	Hybrid = BM25 0.4 + all-MiniLM-L6-v2 0.6，K=5；Graph 最多 4 跳/新增 8 条
作答	`deepseek-flash`，温度 0，最大输出 128 token；三组共用相同问题、Memory、规则和提示词
对照	固定 Hybrid K=5；每题强制 Graph；当前自适应 Graph
指标	英文 token F1、EM、Memory 证据召回、候选数、答案模型输入 Token、拒答/错误；Gold 只在检索与生成后评分

3.3 自动化门禁

Python 全量测试 **198 passed**；前端 TypeScript 检查和 Vite production build 通过；628/628 个唯一 DeepSeek 上下文完成，最终生成错误为 0。每次外部请求立即 checkpoint，结果包保留题单、Memory、提示词与源码 SHA-256，密钥未写入代码、日志或报告。

4. 整体方法与模型对比

4.1 当前同配置正式对照（340 题）

方法	F1	EM	Memory 召回	平均候选	平均输入 Token	拒答	错误
Fixed K5	0.4546	0.2765	59.92%	5.00	825.1	102	0
Forced Graph	0.4784	0.2853	**66.55%**	9.75	1,263.2	85	0
Adaptive Graph	**0.4859**	**0.2941**	63.60%	6.43	955.5	83	0

在当前同版本中，Graph 的净贡献应按 `0.4546 → 0.4859` 计，即 **+0.0313（3.13 个百分点）**，不是 10 个百分点。与旧版 0.3896 相比的总增量还包含答案约束、路由、过滤和参数的联合修正。

自适应 Graph 相对固定 K 有 16 题提升、0 题下降、324 题不变；平均 F1 差的 bootstrap 95% CI 为 `[+0.0156, +0.0495]`。相比强制 Graph，其 F1 点估计再高 0.0075，同时候选减少约 34%、输入 Token 减少约 24%；但该 F1 差的置信区间跨 0，因而主要结论是“更稳定、更省上下文”，而非宣称必然胜出。

4.2 为什么 Full Text 历史结果较高

历史方法	F1	EM	Memory 召回	平均候选	平均输入 Token
Full Text	**0.5043**	0.2324	—	—	19,983.2
Embedding K5	0.4069	0.2029	59.2%	5.00	639.0
Hybrid K5	0.3976	0.2029	59.9%	5.00	669.1
K5 + 补检	0.4075	0.2088	65.0%	6.81	828.8
Hybrid K10	0.4243	0.2059	67.5%	9.99	1,082.4

Full Text 把完整对话交给模型，因而几乎不受“关键证据没进候选”的上限约束；但平均输入约 **19,983 token**，仍会因时间变化、长上下文噪声、词面表达和错误拒答而无法接近 1.0。

当前自适应 Graph 平均只用 955.5 输入 token，其 F1 距历史 Full Text 仅 0.0184。由于两者来自不同提示词/输出预算版本，Full Text 只作历史参考上限，不将 95% 的 Token 差直接包装成严格的同轮效率结论。GLM-4-Flash 的旧 Full Text 有 300/340 协议错误，不作语义能力证据；最终 Graph 对照因而固定使用稳定的 `deepseek-flash`。

5. Graph 消融、局限与结论

5.1 召回—干扰—成本折中

对比	召回变化	F1 变化	代价/解释
Fixed → Forced	59.92% → 66.55%	0.4546 → 0.4784	平均 9.75 条候选；25 题提升、14 题下降，说明证据更多也会干扰作答。
Fixed → Adaptive	59.92% → 63.60%	0.4546 → **0.4859**	平均 6.43 条候选；仅对拒答/明确列表题重建证据，16 升/0 降。
Forced → Adaptive	66.55% → 63.60%	0.4784 → 0.4859	牺牲少量召回，换取更少候选和输入；不在已能回答的简单题中强行注入图证据。

正案例：`What are Maria's dogs' names?` 的 Top-K 只含 Shadow；Graph 通过同槽位 `NEXT_STATE` 找回 Coco，答案由 `Shadow` 补全为 `Shadow and Coco`，该题 F1=1.0。 **边界**：某些题即使召回更多证据，模型仍可能选错时间、使用近义表达或缺失列表项；因此召回与答案 F1 必须分开报告。

5.2 局限与威胁

1. 自定 4 开发/2 测试划分，340 题已暴露且仅为单轮问答，不能外推到开放域或生产对话。
2. 课程未提供完整端到端关系/Effective Memory 金标；小型关系回归不写成真实 QA 状态准确率。
3. 英文 token F1/EM 惩罚近义词、额外解释与日期表达，不等于人类语义正确率。
4. 当前正式 Graph 对照只使用 DeepSeek Flash；Graph 为有界结构遍历，不是开放式因果推理 Agent，也不代表已实现 Memory 压缩。

5.3 结论

项目完成了课程要求的结构化 Memory、动态关系、有效记忆选择、有据作答、Web 可视化和可复现评测，并实现了 Graph Memory/自适应检索附加功能。正式 340 题实验显示，自适应 Graph 将同版本固定 K 的 F1 从 0.4546 提高到 0.4859，EM 从 0.2765 提高到 0.2941，且成对比较中无下降题。实验同时说明：成熟的动态记忆系统不应追求“始终取回更多”，而应在证据不足时有目的地重建局部记忆，并以可追溯引用和失败保守性约束模型。

参考与结果入口：Maharana et al., *Evaluating Very Long-Term Conversational Memory of LLM Agents*, ACL 2024；*DimMem: Dimensional Structuring for Efficient Long-Term Agent Memory*；*MRAgent: Memory is Reconstructed, Not Retrieved*；仓库 `dynamic-memory-system`；正式结果 `evaluation/results/llm-comparison/graph-memory-deepseek-adaptive-final-v2/`。